

Generative Sequence Representation Learning for Biological Sequence Classification

針對生物序列分類的生成式序列表徵學習

Final Project

第四組

Hsunwei Chou, Hongchun Chen, Yuxiang Liao, Hongrui Chen and Chekai Chang

Main Task 主要任務

- 基於蛋白質/胜肽序列數據，進行抗微生物胜肽 (AMP) 的二元分類。
- 核心理念：
 - 利用序列衍生的特徵表示法訓練基準分類器。
 - 使用 VAE 學習生成式潛在表示法以產生合成特徵嵌入。
 - 評估生成式資料增強是否能有效提升生物序列分類的準確度。

Biological Background 生物背景

- 抗微生物胜肽 (AMPs, antimicrobial peptides) :
 - 能夠抑制或殺死微生物的短蛋白質 / 胜肽序列。
 - 能刺激並調控免疫細胞，增強生物體整體的抗病能力。
 - 天然免疫系統的重要成分。

Research Significance 研究價值

- 希望能夠解決：
 - 在實驗室合成並篩選胜肽耗時且成本高昂。
 - 正樣本通常非常稀少且難以取得。
 - 與傳統化學抗生素相比，細菌極難對 AMP 產生抗藥性，具新一代藥物開發潛力。

Dataset 資料集

- 經平衡處理的 AMPlify 資料集：
 - AMPlify_AMP_train_common.fa 、
 - AMPlify_non_AMP_train_balanced.fa 、
 - AMPlify_AMP_test_common.fa 、
 - AMPlify_non_AMP_test_balanced.fa 。
- 其中，官方測試集將直接保留作為最終的測試集，而驗證集則是從官方訓練集中劃分切分而來。

Preprocessing 前處理

- 首先是資料清理與切分：
 1. 讀取 AMPlify FASTA 資料集，轉換成資料表格；
 2. 統一序列格式 (全大寫、去除 * 號)；
 3. 僅保留 20 種標準胺基酸；
 4. 移除空序列與重複序列；
 5. 保留官方測試集，建立訓練、驗證切分；
 6. 建立二元標籤 ($\text{AMP} = 1, \text{Non-AMP} = 0$)；
 7. 進行探索性資料分析 (標籤、長度分布)。

Preprocessing 前處理

- 再來是資料特徵建構：
 - Amino Acid Composition (20 維)，統計 20 種胺基酸比例；
 - Dipeptide Frequency (400 維)，使用 2-mer 所以是 $20 * 20$ 維；
 - Biochemical Features (7 個生化特徵)：序列長度、疏水胺基酸比例、帶電胺基酸比例、芳香族比例、極性胺基酸比例、半胱胺酸比例。
- 最後得到一個 427 維的數值特徵向量，後續 Logistic Regression 和 VAE 都將以這個向量作為輸入。

Baseline Models 基準模型

- 兩個基準模型：
 - Dummy Classifier：幾乎等於亂猜，當作最低基準。
 - Logistic Regression：運算速度快、模型輕量、容易解釋、訓練成本低且主要用來解決二元分類問題的邏輯迴歸模型。
- 若複雜的 VAE 無法打敗一個簡單的基準模型，則沒啥價值。

VAE for Sequence Representation Learning


用於序列表示學習的變分自動編碼器

- VAE 能夠學習序列特徵向量的機率潛在表示法：
 - 對於每個特徵向量 x ，編碼器會輸出： $[\mu(x), \log \sigma^2(x)]$ ；
 - 接著利用重新參數化技巧採樣出一個潛在向量 z ： $z = \mu + \sigma \odot \epsilon$, $\epsilon \sim \mathcal{N}(0, I)$ ；
 - 解碼器則負責重構出原始的特徵向量，其損失函數為： $\mathcal{L} = \text{MSE}(x, \hat{x}) + \beta D_{KL}(q_\phi(z|x) || p(z))$ 。
- VAE 的主要用途包括：
 - 降維與表徵學習：學習低維度的潛在空間表示法。
 - 生物結構視覺化：將生物序列的結構特徵進行視覺化分析。
 - 生成式資料增強：生成合成的特徵嵌入，以用於增強訓練資料。

Extract VAE Latent Embeddings 提取 VAE 潛在嵌入

- 在分類階段，直接使用編碼器輸出的平均值 $\mu(x)$ 作為確定性潛在表徵，以供下游的分類與視覺化任務使用：
 - $\mu(x)$ 代表序列在潛在空間中的位置。
 - 每次輸出固定，不受隨機取樣影響。
- 接著把這些潛在嵌入當作新的特徵輸入 Logistic Regression 進行分類。

Extract VAE Latent Embeddings 提取 VAE 潛在嵌入




Synthetic Feature Generation 合成特徵生成


- 生成式學習流程：
 1. 將訓練資料編碼為潛在向量。
 2. 在潛在空間中，針對每一個類別擬合出簡單的類別高斯分佈。
 3. 從各個類別的分佈中抽樣出潛在向量。
 4. 將抽樣出的潛在向量解碼為合成特徵向量。
 5. 將這些合成特徵加回訓練集中。
 6. 重新訓練分類器。
 7. 最後拿官方測試集進行效能評估。
- 這裡生成的是合成特徵嵌入，而不是全新的真實胺基酸序列。這不等同於在生物學上真正創造出了一條具有實際功能的新胜肽。

Synthetic Feature Generation 合成特徵生成


PCA: Real vs Synthetic Feature Embeddings





PCA: Real vs Synthetic Latent Vectors



Result 結果



Result 結果



Discussion 討論

- VAE synthetic augmentation 幾乎一樣好，但沒有真正超過基準模型：
 - 簡單但有生物意義的特徵，可能比複雜的生成式表示更穩定。
 - VAE 產生的合成特徵沒有明顯幫到模型。
 - 在這份資料與這個設計下，資料增強效果有限。
 - 沒有把結果變更糟，表示生成的特徵還算有合理性。
- 只用 VAE latent + Logistic Regression 反而更差：
 - VAE 壓縮過程丟掉了一部分對於分類重要的資訊。
 - 潛在空間學到的是重建資料的結構，不一定是最有利於分類的結構。

Error Analysis 錯誤分析

- 根據平均特徵結果：
 - False negatives 較短：可能因短序列的 k-mer 組合資訊比較少或模式不明顯。
 - False positives 較長：可能表示某些長 non-AMP 只要在局部區段看起來像 AMP，模型就會誤判。
 - False negatives 的負電比例比較高、False positives 的正電比例較高：可能因絕大多 AMP 帶正電。

error_type	seq_len	hydrophobic_frac	positive_frac	negative_frac	aromatic_frac
correct	28.971	0.422	0.154	0.067	0.091
false_negative	20.889	0.379	0.144	0.100	0.119
false_positive	37.937	0.370	0.169	0.075	0.101

Limitations 限制

- VAE 只在特徵空間生成，不是真正生成胺基酸序列。
- 解碼後的特徵不一定有生物學可行性。
- VAE augmentation 沒有明顯優於強基準模型。
- 模型集中在單一資料集。

Possible Improvements 未來改進方向

- 嘗試直接生成 胺基酸序列，這樣輸出才更接近真實生物應用。
- 改用蛋白質語言模型或 Transformer 類方法，讓表示學習更能捕捉遠距依賴與更高階的序列語意。
- 限制序列合法性、胺基酸分布、長度範圍和理化性質範圍，避免生成的樣本在生物上不合理。
- 加入交叉驗證、外部資料集測試或比較更多模型，確認不是只有在 AMPlify 上有效。
- 把潛在空間也拿來做 clustering、視覺化或下游屬性預測，看潛在表徵保留了哪些資訊。

Final Summary 總結

- 我們以 AMPlify 資料集進行 AMP / non-AMP 二元分類。
- 我們比較了傳統人工特徵、VAE latent representation，以及 VAE synthetic augmentation。
- Feature + Logistic Regression 表現最佳。
- VAE synthetic augmentation 的表現與 baseline 接近，但沒有明顯提升。
- VAE latent representation 雖然能壓縮特徵並學到低維表示，但分類效果不如原始特徵。
- 在這個任務中，具可解釋性的手工特徵仍然非常強，而生成式表示學習不一定優於傳統方法。

Q & A

Thank you!